FACULDADE DE CIÊNCIAS HUMANAS E SOCIAIS – FACIHUS
CENTRO UNIVERSITÁRIO MÁRIO PALMÉRIO – UNIFUCAMP
CURSO DE BACHARELADO EM CIÊNCIAS DA COMPUTAÇÃO.

OSVALDO MOURA NETO
MAURO ANTÔNIO PIRES

ANÁLISE DA EVOLUÇÃO DA "INTELIGÊNCIA" EM CHATBOTS: DA IMPLEMENTAÇÃO BASEADA EM REGRAS A MODELOS PROBABILÍSTICOS.

MONTE CARMELO – MG

MARÇO DE 2026

OSVALDO MOURA NETO
MAURO ANTÔNIO PIRES

Síntese apresentada à disciplina de Inteligência Artificial II para Ciência da Computação, sob a orientação do professor Gustavo Henrique Ribeiro Magalhães.

MONTE CARMELO – MG
MARÇO DE 2026

Sumário

1. OBJETIVO 4
2. INTRODUÇÃO 4
3. DESCRIÇÃO DAS ATIVIDADES 5
3.1 FASE 1: CHATBOT BASEADO EM REGRAS (ELIZA) 5
3.2 FASE 2: MODELO N-GRAM (BIGRAMA) 5
3.3 FASE 3: WORD EMBEDDINGS 6
3.4 FASE 4: TRANSFORMERS 6
4. RESULTADOS OBTIDOS 7
4.1 FASE 1: CHATBOT BASEADO EM REGRAS (ELIZA) 7
4.2 FASE 2: MODELO BASEADO EM N-GRAMS (BIGRAMA) 8
4.3 FASE 3 – WORD EMBEDDINGS (WORD2VEC) 10
4.4 FASE 4: TRANSFORMERS E ATENÇÃO (PORTUGUÊS) 13
5. COMPARAÇÃO DA "INTELIGÊNCIA" PERCEBIDA ENTRE AS FASES 15
6. CONCLUSÃO: IMPACTO DO RLHF 15

1. OBJETIVO

O presente trabalho tem como objetivo desenvolver e analisar diferentes abordagens para a construção de um chatbot, explorando desde modelos baseados em regras até modelos mais modernos como transformers. Busca-se compreender como cada técnica contribui para a simulação de linguagem natural, bem como comparar a evolução da "inteligência" percebida ao longo das fases implementadas, além de identificar as vantagens e limitações de cada abordagem no contexto do processamento de linguagem natural.

2. INTRODUÇÃO

O Processamento de Linguagem Natural (PLN) tem como objetivo desenvolver sistemas capazes de compreender e gerar linguagem humana de forma automatizada. Ao longo do tempo, diferentes abordagens foram propostas para resolver esse problema, evoluindo desde modelos simples baseados em regras até modelos avançados baseados em redes neurais e mecanismos de atenção.

Inicialmente, os sistemas eram baseados em regras simbólicas, como o ELIZA, que utilizava padrões pré-definidos para simular uma conversa, porém sem compreensão real do significado das frases. Com o avanço da área, surgiram abordagens estatísticas, como os modelos N-gram, que passaram a utilizar probabilidades baseadas na frequência de palavras para gerar texto, introduzindo maior flexibilidade, mas ainda com limitações de contexto.

Posteriormente, foram desenvolvidos modelos baseados em representações vetoriais, como os Word Embeddings, que permitem capturar relações semânticas entre palavras ao representá-las em um espaço vetorial. Por fim, os modelos mais modernos, como os Transformers, utilizam mecanismos de atenção (self-attention) para considerar o contexto global da frase, proporcionando avanços significativos na compreensão e geração de linguagem. Dessa forma, este trabalho tem como foco explorar essa evolução, implementando diferentes abordagens e analisando a progressão da "inteligência" percebida em cada uma das fases.

3. DESCRIÇÃO DAS ATIVIDADES

3.1 FASE 1: CHATBOT BASEADO EM REGRAS (ELIZA)

Na primeira fase, foi desenvolvido um chatbot inspirado no sistema ELIZA (1966), caracterizado por uma abordagem simbólica baseada em regras. O objetivo dessa etapa foi simular uma conversa utilizando padrões pré-definidos, sem qualquer tipo de aprendizado automático.

O sistema foi implementado em Python e utiliza expressões regulares (Regex) para identificar padrões nas mensagens do usuário. Cada padrão está associado a um conjunto de respostas previamente definidas, armazenadas em uma estrutura de dados do tipo dicionário.

Durante a execução, a mensagem do usuário é analisada e comparada com os padrões existentes. Quando uma correspondência é encontrada, o sistema seleciona aleatoriamente uma resposta associada. Em alguns casos, partes da entrada do usuário são capturadas e reutilizadas na resposta, tornando a interação mais dinâmica.

Essa abordagem permite simular um diálogo simples, especialmente em contextos previsíveis, como perguntas sobre sentimentos, estado emocional e relações pessoais.

3.2 FASE 2: MODELO N-GRAM (BIGRAMA)

Na segunda fase, foi implementado um modelo estatístico baseado em N-grams, mais especificamente bigramas, com o objetivo de gerar texto a partir de probabilidades calculadas sobre um corpus.

Inicialmente, foi realizado o pré-processamento do texto, incluindo a conversão para letras minúsculas, remoção de caracteres especiais e separação em frases. Em seguida, cada frase foi tokenizada em palavras, sendo adicionados marcadores de início (<s>) e fim (</s>).

A partir dessas sequências, foi construído um modelo de bigramas, no qual cada palavra é associada às possíveis palavras seguintes. Com base na frequência dessas ocorrências, foram calculadas as probabilidades de transição entre palavras.

O sistema também inclui um mecanismo de geração de texto, no qual a próxima palavra é escolhida com base nessas probabilidades, permitindo a criação automática de frases. Além disso, foi implementado um modo interativo que possibilita ao usuário explorar as probabilidades e observar a geração de texto a partir de diferentes palavras iniciais.

3.3 FASE 3: WORD EMBEDDINGS

Na terceira fase, foi utilizada a abordagem de Word Embeddings, na qual as palavras são representadas como vetores em um espaço vetorial. Diferente das abordagens anteriores, essa técnica permite capturar relações semânticas entre palavras, aproximando termos com significados semelhantes.

Para isso, utilizamos a biblioteca Gensim, possibilitando o treinamento ou uso de modelos pré-treinados, como o Word2Vec. A similaridade entre palavras será medida por meio do cosseno entre vetores, permitindo identificar relações semânticas no texto.

3.4 FASE 4: TRANSFORMERS

Na quarta fase, foi explorada a utilização de modelos baseados em Transformers, considerados o estado da arte no processamento de linguagem natural. Esses modelos utilizam mecanismos de atenção (self-attention) para analisar o contexto global de uma frase, superando as limitações dos modelos anteriores.

Será utilizada a biblioteca Hugging Face para executar modelos pré-treinados, como GPT-2 ou BERT, permitindo a geração e análise de texto com maior coerência e compreensão contextual.

4. RESULTADOS OBTIDOS

4.1 FASE 1: CHATBOT BASEADO EM REGRAS (ELIZA)

Durante os testes realizados com o chatbot baseado em regras, foi possível observar que o sistema responde de forma coerente quando a entrada do usuário corresponde aos padrões previamente definidos.

Por exemplo:

```
Eliza: Continue, estou ouvindo.
Você:oi
Eliza: Olá, estou aqui para te ouvir.
Você:estou triste
Eliza: Por que você está triste?
Você:me sinto cansado
Eliza: Por que você se sente cansado?
```

Porém, pode-se observar que o sistema apresenta diversas limitações. Ele funciona adequadamente apenas dentro de um conjunto de palavras previamente definidas. Caso o usuário digite frases que não correspondem a esses padrões, o chatbot passa a responder de forma genérica e repetitiva, tentando direcionar a conversa para algum padrão conhecido.

Isso pode dar a impressão de um “looping”, no qual o sistema insiste em perguntas semelhantes, na tentativa de forçar o usuário a utilizar palavras que ele reconhece.

Exemplo:

Frase: *“Meu professor se chama Gustavo”*

```
Você:meu professor se chama gustavo
Eliza: Isso é importante para você?
Você:meu professor se chama gustavo
Eliza: Como isso faz você se sentir?
Você:meu professor se chama gustavo
Eliza: Me conte mais sobre isso.
Você:meu professor se chama gustavo
Eliza: O que você acha disso?
Você:meu professor se chama gustavo
Eliza: O que você acha disso?
Você:meu professor se chama gustavo
Eliza: O que você acha disso?
Você:meu professor se chama gustavo
Eliza: Como você reage a isso?
Você:meu professor se chama gustavo
Eliza: Como isso faz você se sentir?
Você:meu professor se chama gustavo
Eliza: Como você reage a isso?
```

Como essa frase não contém palavras previamente definidas nos padrões do sistema, o chatbot não consegue interpretá-la corretamente, permanecendo em respostas genéricas e limitadas. Esse comportamento evidencia que o chatbot não possui compreensão semântica da linguagem, baseando-se exclusivamente em correspondência de padrões.

4.2 FASE 2: MODELO BASEADO EM N-GRAMS (BIGRAMA)

Durante os testes realizados com o algoritmo de N-grams, mais especificamente o modelo de bigramas, foi possível observar que o sistema, com base em palavras anteriores e probabilidades, consegue prever qual palavra tem maior chance de aparecer em seguida. Dessa forma, ele consegue gerar frases mais coerentes em comparação com o modelo anterior baseado em regras.

Exemplo:

```
MODELO N-GRAM (BIGRAMA)

Exemplo de probabilidades:

Dado 'você', próxima palavra:
</s>                 22.2%
já                   22.2%
está                 11.1%
gosta                11.1%
prefere              11.1%
vai                  11.1%
pode                 11.1%

Dado 'estou', próxima palavra:
bem                  33.3%
estudando            33.3%
fazendo              33.3%

Demonstração da limitação do contexto:

Textos CURTOS:
→ sim estou fazendo agora ficou mais
→ qual é a sua dúvida
→ estou bem e c

Textos LONGOS:
→ você já fez algum projeto
→ entendi agora
→ estou fazendo agora
```

Com base em um texto utilizado para treinamento, o modelo calcula a probabilidade de ocorrência das palavras. Assim, ao analisar uma palavra como “você”, o sistema identifica quais palavras mais frequentemente aparecem após ela no corpus de treinamento, gerando respostas com base nessas probabilidades.

DEMONSTRAÇÃO DA BASE DE TREINAMENTO

```
CORPUS = """
oi tudo bem com você
estou bem e você
o que você está fazendo agora
estou estudando para a prova
você gosta de programação
sim eu gosto muito de programação
qual linguagem você prefere
eu prefiro python e c mais uso c
você já fez algum projeto interessante
você já foi ao bar
sim estou fazendo um chatbot simples
isso parece muito legal
quando você vai terminar o projeto
acho que termino essa semana
você pode me ajudar com uma dúvida
claro qual é a sua dúvida
não entendi como funciona n gram
n gram usa probabilidade de palavras anteriores
entendi agora ficou mais claro
que bom fico feliz em ajudar
"""
```

Observamos que apesar da melhoria em relação à fase anterior, foram identificadas diversas limitações no modelo de bigramas:

- O modelo é totalmente dependente do conjunto de dados de treinamento, ou seja, ele só consegue gerar palavras e combinações que já apareceram anteriormente.
- Caso o usuário utilize palavras que não existem no treinamento, o sistema não consegue gerar respostas adequadas.
- Em situações onde não há uma palavra subsequente registrada (por exemplo, no final de frases), o modelo pode falhar e não conseguir continuar a geração.
- O modelo considera apenas a palavra imediatamente anterior, não sendo capaz de entender o contexto completo da frase.
- Mesmo sendo gramaticalmente plausíveis, as frases podem não fazer sentido lógico.
- Problema de sparsidade de dados: quanto maior o vocabulário, menor a chance de combinações aparecerem no treinamento, o que reduz a capacidade do modelo.
- Ausência de aprendizado contínuo: o modelo não aprende com novas interações, sendo necessário um novo treinamento para incorporar novos dados.

4.3 FASE 3 – WORD EMBEDDINGS (WORD2VEC)

Na terceira fase, foi implementado um modelo baseado em Word Embeddings utilizando a biblioteca Gensim. Diferente das fases anteriores, que dependiam de regras fixas ou probabilidades locais, este modelo representa palavras como vetores em um espaço multidimensional, permitindo capturar relações semânticas entre palavras.

Parte do Corpus:

```
CORPUS = """
oi tudo bem com você
estou bem e você
o que você está fazendo agora
estou estudando para a prova
você gosta de programação
sim eu gosto muito de programação
qual linguagem você prefere
eu gosto de python
programação é divertida
estudar python é interessante
python é uma linguagem de programação
python é muito fácil de aprender
programação com python é incrível
desenvolvimento web usa python
ciência de dados usa python
inteligência artificial usa python
python tem uma comunidade grande
eu amo programação e desenvolvimento
programar é meu hobby favorito
código bem escrito é importante
ferramentas de programação python
aprender python é fácil e divertido
```

O **corpus** utilizado incluiu frases relacionadas a programação, linguagens de desenvolvimento, algoritmos e conceitos de computação, como “programação é divertida”, “python é uma linguagem de programação” e “desenvolvedor cria soluções”. Após o pré-processamento, as sentenças foram tokenizadas em palavras, removendo caracteres especiais e convertendo todas as palavras para minúsculo.

O modelo Word2Vec foi treinado utilizando Skip-gram (sg=1) com vetor de dimensão 50 (vector_size=50) e janela de contexto de 3 palavras (window=3). Esse modelo permite:

- Identificar palavras semanticamente próximas: por exemplo, palavras próximas de *python* incluem *servidor, estudando, testar*.

- Calcular similaridade entre palavras: por exemplo, a similaridade entre *programação* e *python* foi baixa (0.02), indicando que no corpus essas palavras aparecem em contextos distintos.
- Realizar operações vetoriais (analogias): é possível combinar vetores de palavras para encontrar relações semânticas, como python + web ou programação - dificuldade + diversão.

Também, foi possível visualizar o espaço vetorial em 2D usando PCA, observando que palavras com contextos semelhantes formam clusters próximos, como *python, django, web* ou *código, programa*.

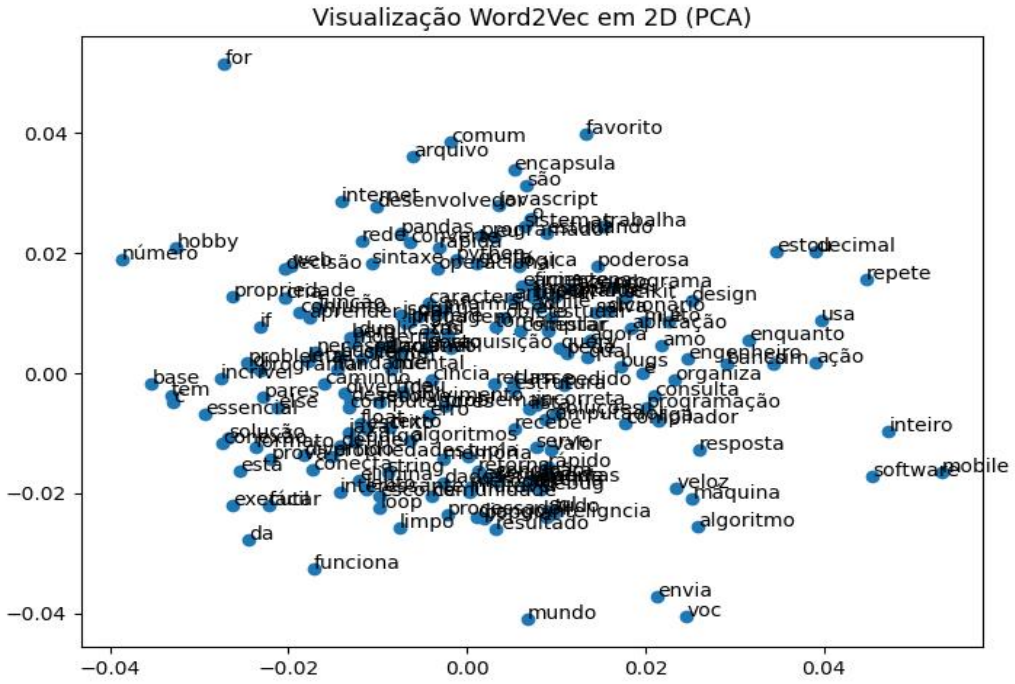

Exemplo de operação e resultados:

- *Python + Web*: palavras próximas retornadas foram *servidor, desenvolvedor, fazendo*.
- *Programação - Difícil + Diversão*: palavras próximas foram *agora, software, pede*.
- *Python + Estudar*: palavras próximas foram *servidor, programa, estudando*.

Esses exemplos demonstram que o modelo consegue capturar relações de contexto e semântica entre palavras, indo além das probabilidades simples do N-gram.Porém apesar de melhorar significativamente a compreensão semântica em relação às fases anteriores, o Word2Vec apresenta algumas limitações:

1. Dependência do corpus: palavras ou conceitos que não aparecem no corpus não podem ser corretamente relacionados.
2. Contexto limitado por palavra**:** cada palavra possui um vetor fixo, sem considerar a posição exata na frase.
3. Analogia imperfeita: operações vetoriais podem não gerar resultados intuitivos, principalmente em corpora pequenos ou muito específicos.
4. Não aprende de forma contínua: novas interações não são incorporadas sem novo treinamento.

Em comparação com as fases anteriores, o Word2Vec permite uma percepção de "inteligência" mais avançada, pois entende relações semânticas e contextos mesmo que não tenham sido programados explicitamente, superando limitações do modelo baseado em regras e do N-gram.

4.4 FASE 4: TRANSFORMERS E ATENÇÃO (PORTUGUÊS)

Na quarta fase, foi explorado o uso de Transformers, uma arquitetura de ponta em NLP, que substitui modelos baseados em regras ou N-Grams. Diferente das fases anteriores, os Transformers processam toda a frase de uma vez e utilizam o mecanismo de Self-Attention, permitindo identificar quais palavras são mais relevantes para compreender o contexto global.

4.4.1 GPT-2: Geração de Texto

Foi utilizado o modelo pierreguillou/gpt2-small-portuguese para gerar textos em português. O GPT-2 é um modelo autoregressivo, que prevê a próxima palavra com base no contexto anterior da frase.

Exemplos de geração de texto:

- Entrada: *"O avanço da inteligência artificial"* Continuação gerada: *"começou em março de 2014. O programa será implementado nos próximos anos."*
- Entrada: *"A ciência descobriu que"* Continuação gerada: *"a temperatura do ar é determinada pela pressão e temperatura da água do sistema."*
- Entrada: *"O futuro da tecnologia é"* Continuação gerada: *"um caminho ao sucesso e ao crescimento da empresa."*

O GPT-2 demonstrou coerência contextual, mantendo fluidez na geração de textos, mesmo em entradas curtas.

4.4.2 BERT: PREENCHIMENTO DE LACUNAS ([MASK])

Foi utilizado o modelo neuralmind/bert-base-portuguese-cased, um Masked Language Model, capaz de prever palavras faltantes considerando o contexto antes e depois da lacuna.

Exemplos:

- Frase: *"Lisboa é a capital de [MASK]."* Previsão principal: *Portugal* (96,04%)
- Frase: *"O gato está em cima do [MASK]."* Previsão principal: *muro* (34,34%)

O BERT mostra como Transformers conseguem entender relações semânticas complexas e preencher lacunas de forma precisa.

- Limitações observadas:
  - Necessidade de modelos pré-treinados robustos para gerar resultados confiáveis.
  - Requer mais capacidade computacional que modelos anteriores.
  - GPT-2 pode gerar texto plausível, mas nem sempre factual ou coerente em corpora restritos.

Comparando com as fases anteriores, os Transformers representam um salto significativo na percepção de “inteligência”, permitindo gerar texto coerente e compreender contexto de forma global, indo muito além de padrões fixos ou probabilidades locais.

5. COMPARAÇÃO DA “INTELIGÊNCIA” PERCEBIDA ENTRE AS FASES

A análise comparativa das quatro fases implementadas evidencia uma progressiva evolução na percepção de inteligência dos sistemas. Na primeira fase, baseada em regras inspiradas no ELIZA, a interação é limitada à correspondência de padrões predefinidos, resultando em respostas genéricas sempre que o usuário digita algo fora do conjunto conhecido. Essa abordagem demonstra uma simulação de diálogo, mas sem qualquer compreensão semântica do conteúdo.

Com a introdução dos N-Grams na segunda fase, observou-se uma melhora na coerência textual, uma vez que o modelo passa a prever palavras subsequentes com base em probabilidades calculadas a partir do corpus de treinamento. Embora mais flexível que a fase anterior, o modelo ainda é restrito ao vocabulário do treinamento e ao contexto imediato, não sendo capaz de compreender frases completas ou conceitos que não estejam presentes nos dados de entrada.

A fase seguinte, utilizando Word Embeddings via Word2Vec, permitiu capturar relações semânticas entre palavras e realizar operações vetoriais, aproximando termos com significados semelhantes. Essa abordagem apresentou um salto qualitativo em relação às anteriores, permitindo identificar contextos e analogias, mas ainda apresenta limitações, como a dependência do corpus e a incapacidade de interpretar o contexto global da frase de forma dinâmica.

Finalmente, a fase baseada em Transformers com GPT-2 e BERT evidenciou o maior nível de inteligência percebida, processando a frase completa de maneira contextualizada e utilizando mecanismos de self-attention para identificar a relevância de cada palavra. Isso possibilita gerar textos coerentes, preencher lacunas e lidar com relações semânticas complexas, superando as limitações das fases anteriores. Apesar de exigir modelos pré-treinados robustos e maior capacidade computacional, a aplicação dos Transformers demonstra a evolução mais significativa na percepção de inteligência, aproximando a interação de uma conversação humana.

6. CONCLUSÃO: IMPACTO DO RLHF

O emprego de Reinforcement Learning with Human Feedback (RLHF) em modelos avançados, como GPT, potencializa ainda mais a percepção de inteligência ao alinhar as respostas do modelo às expectativas humanas. Esse aprendizado guiado por feedback permite reduzir respostas incoerentes ou inadequadas, aprimorando a fluidez e a utilidade prática das interações.

Portanto, enquanto os modelos baseados em regras e N-Grams oferecem apenas simulações de conversação limitadas, os Transformers com RLHF proporcionam respostas contextuais, coerentes e adaptadas ao usuário, consolidando a evolução observada nas fases anteriores e evidenciando o impacto positivo do aprendizado supervisionado por feedback humano na qualidade da inteligência percebida.